

日本語教育のための 漢字・漢語データベース

野村雅昭
山下喜代

1. 研究の目的

日本語教育の進展に伴い、外国人学習者のための基本漢字・基本語彙を選定することの必要性は、日を追って高まっている。もちろん、これまでも、それを目標とした試みは幾つか存在した。しかし、日本語教育の世界で、これが標準だとされるものは、まだ実現していない。それには、いろいろの理由が考えられるが、もっとも大きなものは、その基礎となる良質の資料の整備が遅れていることである。

基本漢字にせよ、基本語彙にせよ、それが現実使用されている日本語の実態に即して選定されるべきものであることは、いうまでもない。そして、これまでに現代日本語を対象とした各種の調査が実施されている。その調査結果を、日本語教育の観点から整理し、利用しやすい形にとのえることが、目的達成のための基礎的作業の第一歩であると考えられる。

また、利用の便ということでは、従来の資料が印刷物の形をとることが普通だったのに対し、近年はパソコンなどの使用を前提とした電子媒体の利用が顕著になっている。その利点は、従来の資料が一定の目的にそって編集されたのに対し、データベースとして提供することにより、利用者の種々の目的に対応できるようになったことである。つまり、作成者が電子媒体で提供したものを利用者が自由に選択・加工できるようなシステムが

実現可能になったことを、それは意味している。パソコンの普及により、研究者が自分の身边でそれが行えるようになったことも、最近の特徴と言ってよいであろう。

そのような観点から、わたくしたちは本学の特定課題研究「日本語教育のための漢字・漢語データベースの構築」(研究代表者 野村雅昭)を申請し、1991・1992の両年度にわたり、研究補助金を得ることができた。共同研究者は、日本語研究教育センターの専任教員である中村明、鈴木義昭、細川英雄の3名である。作業の遂行には、文学研究科日本語日本文化専攻博士後期課程に在籍する山下喜代、宋永彬が協力した。また、資料の一部には、山下の修士論文「日本語教育のための漢語研究」(1991年度)の成果を利用した。

以下に述べるのは、その研究経過の報告である。執筆は、資料の加工を主として担当した野村と山下が行った。

2. 作業手順およびファイル仕様の概要

本研究では、その基礎資料の選定が重要な意味をもつ。この2年間の作業では、国立国語研究所(以下では「国語研」と略称)が行った用字用語調査のデータを活用することに主眼を置いた。また、日本語教科書については、これまで大規模な調査がなかったので、初級・中級教科書を対象として、調査を実施した。

以上の資料から抽出したデータをパソコンに入力するため、漢字、漢語のそれぞれにつき、基礎ファイルを作成した。基礎ファイルは、今後の作業の台帳としての性格をもつ。漢字ファイルは、国語研の調査に出現した約3,700字を見出しとする。漢語ファイルは、『分類語彙表』(後出)の増補作業の過程で得られた、約22,000語を見出しとしている。

漢字ファイルについては、それぞれの字母について、次の情報を付加することを考慮して、設計した。

【属性情報】

- ① 部首 ② 画数 ③ 字源 ④ 字音 ⑤ 字訓

③ の字源は、いわゆる六書の別のことである。④ と ⑤ には、「常用漢字表」に掲げられた音訓であるか否かの別も記す。

【字種情報】

- ① 学年別配当 ② 国語施策 ③ 字典コード

① は、学習指導要領で定められている初出学年についての情報である。
② は、「当用漢字表」「常用漢字表」などの所収の別である。③ は、『大漢和辞典』（大修館書店）、『新字源』（角川書店）などの検字番号である。

【頻度情報】

- ① 雑誌 ② 新聞 ③ 中学・高校教科書 ④ 日本語教科書

国語研が行った3種の調査(①—③)と日本語教科書の調査(④)における使用頻度と使用順位に関する情報である。それぞれに、層別(使用分野別)の情報がある場合は、それも含める。

漢語ファイルも、基本的には漢字ファイルと類似の構造をもつが、細部については多少異なる。それぞれの見出し語について、次のような情報を付加している。

【属性情報】

- ① 品詞性 ② 語構成 ③ 意味コード

見出しとする漢語は、品詞論的には名詞に属するものが多いが、意味的な性格からは、ア一体言類、イ一用言類、ウ一相言類、エ一副言類のように分類できる。① は、そのような種別を示す。② は、特に二字漢語について、その語構成要素の意味的な結合関係を示す。③ は、その語の所屬する意味分野に関する情報で、『分類語彙表』の番号を付する。

【語種情報】

- ① 出自 ② 中国語

一般に、語種とは和語・漢語・外来語などの区別を指すが、ここでは日本製の漢語であるか、中国製の漢語であるかの区別を言う。また、現代中国語でも用いられるものについては、品詞性や意味の差異についての情報

を②に記す。

【頻度情報】

① 雑誌 ② 新聞 ③ 中学・高校教科書

④ 日本語教科書 ⑤ 児童作文

それぞれの調査における使用頻度と使用順位に関する情報を示すこと、漢字ファイルと同様である。漢字ファイルの調査のほかに、国語研の調査1種(⑤)を加えた。

以上の内容は、最終的にはそれぞれ1種類のファイルにまとめられるものであるが、現在は各情報ごとに別ファイルとなっている。また、情報の内容により、すべての入力完了したファイルと作業中のファイルとがある。情報別ファイルの作業が終わった時点で、漢字データベースと漢語データベースとして、それぞれハードディスク内に収納する予定である。データベース・ソフトとしては、市販の『桐』(管理工学研究所)を用いている。

3. 基礎資料の性格

3.1. 漢字・漢語を対象とする理由

基本漢字を選定するために、現代日本語で使用される漢字の実態をデータ化することが有益であるのは、いうまでもない。しかし、それに比べて、漢語のデータを整備することと基本語彙を確定することには、直接に結びつかないものがあることも、事実である。なぜならば、日本語学習者が初級段階で接する単語の多くは和語である。また、それに比べれば少数ではあるが、外来語も含まれるはずだからである。それにもかかわらず、わたくしたちが漢字とともに漢語を対象とするのは、従来の基本語彙に対する見方とはやや異なる観点から、語彙習得をとらえようとするからにほかならない。

これまでの基本語彙に類する諸案の多くは、日常の会話および多少の読み書きに必要な単語の習得という観点からの試みであった。しかしなが

ら、本学に在籍する外国人学生に限って言えば、日本語教育の普及とともに、来日する以前にかなりの日本語力を身につけているようになった。大学教育に必要な知識語彙の学習という面からは、これまでよりも高度な内容が要求されていると言っても差し支えない。この点は、一般の留学生についても同様の傾向が見られ、単なる会話能力の習得から進んで、かなりの程度の書記言語の習得が望まれる状況に至っている。

この点に関して、日本語の語彙は、話しことばと書きことばの間に大きな隔たりがあることが指摘されている。近代に生産されたり使用されるようになったりした漢語のあるものが話しことばの中に普通に使われるようになったのは、ごく最近のことである。それまでは、きわめて起源の古い漢語が和語化して話しことばになったものはあるが、基本的には話しことばの中核となるものは和語であった。そして、その対極として書きことばは漢語に支えられていた。

そのことの是非はともかくとして、その傾向は今日でも続いている。もちろん、現在の書きことばは、話しことばの基盤の上に成立しているわけであり、和語や外来語を無視して書きことばの語彙を論じることにはできない。しかし、日本語を母語とする学習者が青年期に書きことばを習得するのと同様に、外国人の日本語学習者、特に留学生もまた、その壁を越えることを要求される。しかも、それは話しことばの獲得と平行しつつ短期間に成果を取めなければならない。

そのような観点からは、日本語教育のための基本語彙ということも、従来の考え方から進んで、目的に応じた選定の方策がたてられてもよい時期に至っている。わたくしたちがこの研究で求めようとしているのは、実はそのような語彙の選定の基礎資料の作成である。もう少し具体的に言えば、話しことばの語彙と連続させながら、書きことばの世界に足を踏み入れることを容易にするような語彙指導のあり方を模索することでもある。これまでの基本語彙の試みに、そのような視点が皆無だったわけではないが、現在は特にそれが痛感されるに至っている。

そのことは、このデータベースを構築するために、どのような資料を基礎とするかということと関係する。以下に、具体的な資料と関連づけて、それを説明する。

3.2. 国立国語研究所調査データの性格

国語研では、創立以来各種の用字用語調査が行われている。今回のわたくしたちの作業で、直接にデータ作成の対象としたのは、下記のものである。以下に、その調査結果を載せる文献を掲げる。

[雑誌調査]

国語研報告 21『現代雑誌九十種の用語用字—総記および語彙表—』

(1962. 3, 秀英出版)

同 22『現代雑誌九十種の用語用字—漢字表—』(1963. 3, 秀英出版)

同 25『現代雑誌九十種の用語用字—分析—』(1964. 3, 秀英出版)

[新聞調査]

国語研報告 37『電子計算機による新聞の語彙調査』(1970. 3, 秀英出版)

同 38『電子計算機による新聞の語彙調査 (II)』(1971. 3, 秀英出版)

同 42『電子計算機による新聞の語彙調査 (III)』(1972. 3, 秀英出版)

同 48『電子計算機による新聞の語彙調査 (IV)』(1973. 3, 秀英出版)

同 56『現代新聞の漢字』(1976. 3, 秀英出版)

[中学・高校教科書調査]

国語研報告 76『高校教科書の語彙調査』(1983. 3, 秀英出版)

同 81『高校教科書の語彙調査 (II)』(1984. 3, 秀英出版)

同 87『中学校教科書の語彙調査』(1986. 3, 秀英出版)

同 91『中学校教科書の語彙調査 (II)』(1987. 3, 秀英出版)

同 99『高校・中学校教科書の語彙調査—分析編—』(1989. 3, 秀英出版)

[児童作文調査]

国語研報告 98『児童の作文使用語彙』(1989. 3, 東京書籍)

[分類語彙表]

国語研資料集 6『分類語彙表』(1964. 3, 秀英出版)

野村雅昭・中野洋『「分類語彙表」形式による語彙分類表』(1989. 3, 文部省科学研究費報告書)

[その他]

国語研報告 78『日本語教育のための基本語彙調査』(1984. 3, 秀英出版)

同 95『児童・生徒の常用漢字の習得』(1988. 3, 東京書籍)

これらの大部分は、書きことばに関する調査である。話しことばについての大規模な調査がないことは、日本語教育が通常会話から始まることを考え合わせると、物足りない面があることは否定できない。しかしながら、前項で述べたように、漢字・漢語に焦点を合わせるならば、それほど大きな支障は生じないと見てよい。

漢字に関しては、報告 22, 56, 99 が直接の資料となる。報告 95 は、漢字の提出順序、音訓の選択などに関して、参考となる。雑誌と新聞の調査は、学習者が普通に目にする漢字の使用頻度を知る上で、重要である。教科書の調査は、社会科と理科の教科書が対象となっているが、大学の高等教育における知識的な語彙体系の記述に用いる基礎的な漢字の範囲を把握するのに便利である。いずれにしても、漢字ファイルの字母は、常用漢字を含む現代の日常的な漢字集合を想定する限りでは、十分に条件を満たしていると考えられる。

それに対して、漢語データについては、考慮すべきことがある。それは、調査単位の問題である。上記の各調査は、それぞれに次のような異なる調査単位を用いており、扱いに注意が必要である。

	長い単位	短い単位
雑誌調査	—	β 単位
新聞調査	長単位	短単位
教科書調査	W 単位	M 単位
作文調査	α 単位	—

「長い単位」は、文節を基準とするもので、文節または文節から助辞を除いたものである。長単位と W 単位はほぼ同じである。 α 単位は、それ

よりやや短い。例えば、「国立国語研究所」は、長単位と W 単位では一つの単位であるが、 α 単位では「国立 / 国語研究所」のように、二つの単位に分割される。

「短い単位」は、形態素を基準とするもので、一つの形態素または二つの形態素の一次結合形が単位となる。和語については、例えば「雪国」は、 β 単位・短単位とも一つの単位であるが、M 単位では「雪 / 国」のように分割される。ただし、漢語に関しては、3 種の単位とも、ほぼ同じ規則で、例えば「国立 / 国語 / 研究 / 所」のように分割されるので、単位間の不統一はない。

問題となるのは、「長い単位」と「短い単位」のどちらか一方しか採用していない場合である。新聞調査と教科書調査は、両者を併用しているが、雑誌調査と作文調査は、それぞれ 1 種類のみである。例えば、雑誌調査では、「飛行 / 機」「自動 / 車」は二つの単位に分かれ、「飛行機」「自動車」という語形は存在しない。逆に、作文調査では、「国際的」「国際人」「国際問題」などの見出し語はあっても、「国際」という語形が何回出現したかは、集計されていない。

このような事情から、わたくしたちの調査では、漢語ファイルの見出し語を選ぶために、第一次資料として、『分類語彙表』を用いることにした。『分類語彙表』は、雑誌調査を主な資料として、約 3 万 7 千語を選んだものである。ただし、そのような制約から、「長い単位」に相当する語が漏れているきらいがあり、現在増補作業を進めているところである。増補の結果は、まだ確定していないが、約 6 万語程度になる見込みである。

わたくしたちの作業では、その増補途中のデータを借用することとした。そして、まず二字漢語を抽出して、作業を進めている。それが、先に述べた 22,000 語である。次いで、「愛する」「信じる」などのサ変動詞や「一的」「不一」などの接辞を含む一字漢語に着手する予定である。ただし、三字以上の漢語については、方針を確定していない。仮に、三字漢語に限るとしても、かなりの数に上ることが予想される。どの範囲を対象と

するかについては、別の観点が必要である。また、二字漢語についても、現在の見出し語をすべて残すのではなく、なんらかの選択を行わなければならないだろう。

このように、国語研の資料に問題がないわけではない。しかし、現代で使用されている語彙の実態を把握する上で、ほかに匹敵するものがないことも確かである。そのような点からは、これを活用して、使いやすい形に整えることが必要だと考えられる。

3.3. 日本語教科書データの性格

3.3.1. 対象とした日本語教科書

国内で出版された日本語教科書初級10種と中級5種を対象とした。教科書の選定に当たっては、「聞く・話す・読む・書く」の四技能の習得を目的とする教科書を主とし、「会話」「聴解」など個別的な言語技能習得のために作成されたものは、原則として除外した。ただし、漢語の採集が目的であるので、中級に「読解」のための教科書を含めた。また、学習対象者を「技術研修生」などに限定している中級教科書は、専門語が出現する可能性があるので除いた。

以下、対象とした各教科書について次の項目に分け、簡単に記述する。

- ① レベル ② 学習対象者 ③ 学習に要する時間
- ④ 語彙数 ⑤ 抽出漢語数

なお、一部のデータは『日本語データファイル 日本語教科書』(1992, 日本語教育学会)を参照した。

[01] 『外国学生用日本語教科書初級(改訂版)』1988.4.1 再訂版9刷 早稲田大学日本語研究教育センター

- ① 初級 ② 留学生 ③ 180時間 ④ 約2000語(助詞・助動詞など除外) ⑤ 864語

* 学習時間は、教科書記載は180時間であるが、上記『日本語データファイル』記載は300時間になっている。

[02] 『初級日本語』1990.9.10 第2刷 三省堂

東京外国語大学附属日本語学校

- ① 初級 ② 留学生 ③ 300時間 ④ 約2000語(自立語約1800)
⑤ 640語

[03] 『現代日本語』1986.5.31 改訂第2版第2刷 亜細亜大学留学生別科

- ① 初級 ② 留学生, 一般人 ③ 150~200時間 ④ 約1300語(固有名詞除外) ⑤ 467語

[04] 『日本語初歩』1986.7.30 改訂版第3刷 国際交流基金

- ① 初級 ② 一般人, 留学生 ③ 300時間 ④ 約1400語 ⑤ 444語

[05] 『横山さんの日本語第1巻~6巻』1989.1.1 日本語教育センター

- ① 初級 ② 一般人 ③ 300時間 ④ / ⑤ 1458語

* 上記『日本語データファイル』では, 第6巻は中級レベルになっているが, ここでは1巻から6巻まで初級扱いにしている。第7巻は「日本語言葉辞典」で, ここではデータ採集の対象にしなかった。学習時間はこの第7巻を含めた数字である。

[06] 『新日本語の基礎 1』1990.12.20 第2刷 海外技術者研修協会

- ① 初級 ② 技術研修者, 一般短期学習者 ③ 100時間 ④ 830語
⑤ 216語

[07] 『別科・日本語 1』1989.3.31 長崎総合科学大学別科

- ① 初級 ② 留学生 ③ 300時間 ④ 約2000語(固有名詞, 複合語除外) ⑤ 844語

[08] 『文化初級日本語 1,2』1987.4.1 文化外国語専門学校

- ① 初級 ② 留学生 ③ 300~350時間 ④ 約1800語 ⑤ 721語

[09] 『日本語でビジネス会話初級編』1986.6 日米会話学院

- ① 初級 ② ビジネスマン, 一般人 ③ 300時間 ④ 約1700語
⑤ 544語

* 日本語によるコミュニケーション能力の習得をめざす教科書で, 本文

はほとんど会話体でなりたっている。しかし読解力の向上を図るためとして、習得した文型を中心にした情動的読み物も加えられている。

- [10] 『日本語 Basic Functional Japanese』1987 The Japan Times

① 初級(入門) ② 英語圏一般人 ③ 90~120時間 ④ 約1500語
⑤ 373語

* コミュニケーション能力の習得を第一の学習目的としており、ヒラガナとカタカナのみ「読み書き」ができることを目指している。したがって、固有名詞以外、漢字表記はほとんど行われていない。この教科書については、「漢字表」の作成資料から除外した。

- [11] 『日本語中級 1』1990.7.25 第1刷 国際交流基金日本語センター

① 中級 ② 一般人 ③ 150時間 ④ 813語(『日本語初歩』既習語彙は除外) ⑤ 385語

- [12] 『総合日本語中級』1989.3.10 初版第2刷 凡人社

① 中級 ② 一般人 ③ 70~120時間 ④ 約3500語 ⑤ 1548語

* 語彙数3500に初級語彙が含まれているか否かは不明である。

- [13] 『中級から学ぶテーマ別日本語』1991.4.25 研究社出版

① 中級 ② 留学生, 一般人 ③ / ④ / ⑤ 438語

- [14] 『コンテンポラリー日本語中級』1990.8.5 第2刷 桜楓社

① 中級 ② 留学生 ③ 100~150時間 ④ 約2500語 ⑤ 592語

* この教科書は「読解のため」のテキストである。語彙数に初級語彙が含まれているか否かは不明。

- [15] 『現代日本語コース中級1,2』1990.1

名古屋大学総合言語センター日本語科

① 中級 ② 留学生 ③ 200時間 ④ / ⑤ 505語

* ⑤の漢語数は各課のなかの「読む練習」に出現した漢語のみ抽出したものである。

以上の15種類の教科書を、表1に一覧として掲げる。

表 1 調査対象とした日本語教科書一覧

コード	レベル	教科書名・発行所	発行年月日	対象者
01	初	外国学生用日本語教科書初級（改訂版） 早稲田大学日本語研究教育センター	1988.4.1 再訂版第9刷	留学生
02	初	初級日本語 東京外国語大学附属日本語学校 三省堂	1990.9.10 第2刷	留学生
03	初	現代日本語 亜細亜大学留学生別科	1986.5.31 改訂2第版第2刷	一般人
04	初	日本語初歩 国際交流基金	1986.7.30 改訂版第3刷	一般人
05	初	横山さんの日本語 日本語教育センター	1989.1.1	一般人
06	初	新日本語の基礎 海外技術者研修協会	1990.12.20 第2刷	技術 研修生
07	初	別科・日本語 1 長崎総合科学大学別科	1989.3.31	留学生
08	初	文化初級日本語 1, 2 文化外国語専門学校	1987.4.1	留学生
09	初	日本語でビジネス会話初級編 日米会話学院	1986.6.	成人
10	初	Basic Functional Japanese The Japan Times	1987	英語圏 成人
11	中	日本語中級 1 国際交流基金日本語国際センター 凡人社	1990.7.25 初版第1刷	海外 一般人
12	中	総合日本語中級 水谷信子 凡人社	1989.3.10 初版第2刷	一般
13	中	中級から学ぶテーマ別日本語 研究社出版	1991.4.25 初版	学生 一般
14	中	コンテンポラリー日本語中級 桜楓社	1990.8.5 第2刷	学生 一般
15	中	現代日本語コース中級 1, 2 名古屋大学総合言語センター日本語科	1990.1	留学生

3.3.2. 語彙表と漢字表の内容

上記教科書を資料として、3種類の【語彙表】と1種類の【漢字表】を作成した。

【語彙表1】は、それぞれの教科書の巻末索引あるいは「課」ごとの単語表から、「漢語」(字音語)と「漢語を含む漢字表記混種語」を抽出し(延べ語数—10,050, 異なり語数—4,470), 作成した。固有名詞は除外したが国名は収録した。抽出単位は教科書に提出されている単位(出現形)とし、それを語彙表の「見出し語」に立てた。それら「見出し語」について「読み・意味分類・表記・教科書出現度数・他の語彙表収録状況」などの情報を載せた。

「意味分類」は『分類語彙表』および『分類語彙表』形式による語彙分類表の分類に従い、番号を当てた。「表記」は、それぞれの「見出し語」が教科書でどのように表記されているかを示した。「教科書出現度数」は15種の教科書のうち何種に出現するかを点数で表したもので、初級、中級それぞれの出現度数およびその合計を算出した。「他語彙表収録状況」とは、国語研『日本語教育のための基本語彙調査』の「日本語教育基本語彙五十音順表」に収録されている「他語彙表」における収録状況を転載したものである。表2は、その「他語彙表一覧」である。

【語彙表2】は【語彙表1】の「見出し語」を β 単位に変え、『分類語彙表』の意味分類にならない番号をつけ、『日本語教育のための基本語彙調査分類語彙表』の配列に従って作表した「分類語彙表」である。「見出し語」は約3520語となった。

【語彙表3】は【語彙表2】を五十音順に配列したものである。

【漢字表】は【語彙表3】と【語彙表1】の「表記」についての情報をもとに作成した。【語彙表3】の漢語および混種語を分解して構成要素の漢字(1476字)を抽出した。これらは大部分が字音として用いられている漢字であるが、混種語から抽出された字訓も一部含まれている。【漢字表】では、字音と字訓あるいは「解(カイ)」「解(ゲ)」などの読み替えを別字と数

表 2 他語彙表一覧

コード	語 彙 表
1	日本語基本語彙 (国際文化振興会, 1944)
2	日本語教育における基礎学習語 (加藤彰彦 日本語教育学会『日本語教育』2 1963.4)
3	Practical Japanese-English Dictionary (玉村文郎 海外技術者研修協会 1970. 1978)
4	A Classified List of Basic Japanese Vocabulary (J. V. Neustupny Monash University, Department of Japanese, Melbourne 1977)
5	外国人のための基本語用例辞典 (文化庁国語課 1971, 1975)
6	留学生教育のための基本語彙表 (吉田弥寿夫・樺島忠夫 大阪外国語大学留学生別科『日本語・日本文化』2)
7	現代雑誌九十種の用字用語第一分冊 (国語研, 1962)

えて得られた1622の漢字を五十音順に配列した。そして、それぞれの漢字について、それらを構成要素としてもつ教科書出現漢語を教科書の表記に従って列挙した。また、対象教科書において、ヒラガナ表記でしか出現しない字音(56字)についてはそれを区別した。

4. 今後の予定

以上に述べたように、この研究は、この2年間でその基礎に当たる部分の作業を終えたところである。これを実用化するためには、新たなプロジェクトを発足させることが必要である。ただし、当面の課題としては、基礎作業にあたる部分だけでも、なおやり残したことがあり、それを完成させることが急務である。

具体的には、各ファイルの情報付加作業の遅れているところを充足させなければならない。そして、ファイルを統合し、データベース化すること

が急がれる。ただし、すべてのファイルの完成を待っているよりも、不完全でも、実験的なシステムを作り、問題点を見つけて、作業に反映させることが効率的である。そのためには、ある程度は全体の計画を縮小することも検討する必要がある。

一方、それとは反対に、実用の面からは、漢語データに用例を付けることも要望されている。これは、ファイルの容量を増大させることになり、パソコン上でデータベースを実現することと矛盾することにもなる。もちろん、大型計算機を使った、端末機からの利用を考えるならば、それも不可能ではない。ただし、当初の目的から言えば、個々の研究者が身近で扱えるようなデータベースの構築からは遠ざかることになる。

それらの問題を解決しつつ、新しいプロジェクトの構想を練ることが差し当たっての課題である。

(1992. 12)